

Retroalimentación formativa con IA generativa en programación: diseño del protocolo y evaluación de resultados

José Vicente Álvarez Bravo¹, María Antonia López Luengo³, María Victoria Vega Agapito³,
Berta San Isidro San Cristobal¹, Diego de Andrés Martín¹ y Francisco Hernando Gallego²

¹Departamento de Informática, Universidad de Valladolid

²Departamento de Matemática Aplicada, Universidad de Valladolid

³Departamento de Didáctica de la C.C. Experimentales, Sociales y de la Matemática, Universidad de Valladolid

jvalvarez@uva.es, mariaantonio.lopez@uva.es, mariavictoria.vega.agapito@uva.es,

berta.sanisidro@uva.es, diego.andres.martin@uva.es, fherando@uva.es

Resumen—Integrar inteligencia artificial generativa como apoyo a la retroalimentación formativa en asignaturas de programación plantea un reto doble: ofrecer orientación personalizada con un gran número de estudiantes y, al mismo tiempo, sostener la autoría, la reflexión y el aprendizaje transferible. Este trabajo presenta una intervención didáctica centrada en el diseño instruccional y en el material de andamiaje que guía al estudiantado para formular prompts, solicitar y validar la retroalimentación, o feedback, iterar y documentar decisiones. La propuesta se articula mediante un ciclo de prácticas guiadas conectadas con un proyecto final, e incluye plantillas de trabajo, ejemplos de diálogo, criterios de calidad y pautas de uso responsable. Para estimar el efecto de la intervención, se emplean como indicadores de impacto el análisis cualitativo longitudinal de los entregables y la calificación del proyecto final. Los hallazgos apuntan a cambios observables en la forma de trabajar con la inteligencia artificial generativa: mayor estructuración, iteración y justificación, con trayectorias de uso diferenciadas. Asimismo, respaldan la viabilidad de un método replicable y trazable para su integración como retroalimentación formativa, especialmente útil en asignaturas basadas en prácticas y proyectos con alta carga docente.

Abstract—Integrating generative artificial intelligence as support for formative feedback in programming courses poses a dual challenge: providing personalized guidance for large numbers of students while, at the same time, preserving authorship, reflection, and transferable learning. This paper presents an instructional intervention centered on instructional design and scaffolding materials that guide students in formulating prompts, requesting and validating feedback, iterating, and documenting decisions. The proposal is structured around a cycle of guided practice tasks connected to a final project, and includes work templates, dialogue examples, quality criteria, and responsible-use guidelines. To estimate the effect of the intervention, the impact indicators used are a longitudinal qualitative analysis of the submitted deliverables and the grade obtained in the final project. The findings point to observable changes in the way students work with generative artificial intelligence, characterized by greater structuring, iteration, and justification, along with differentiated usage trajectories. They also support the viability of a replicable and traceable method for its integration as formative feedback, especially useful in practice- and project-based courses with a high teaching workload.

Palabras clave—Retroalimentación formativa, IA generativa, programación, diseño instruccional, autoría responsable, análisis cualitativo, prácticas guiadas, proyecto final.

I. INTRODUCCIÓN Y MARCO TEÓRICO

La retroalimentación formativa orientada a la mejora antes de la entrega final (en adelante, retroalimentación o *feedback*), es un factor clave para el aprendizaje en educación superior porque clarifica criterios de calidad, orienta la mejora y favorece la autorregulación del estudiante (planificar, revisar y ajustar el propio trabajo con criterios y evidencias). Sin embargo, las tareas con mayor potencial formativo —proyectos, informes técnicos o prácticas de programación— son también las que requieren más esfuerzo para proporcionar comentarios individualizados, oportunos y aplicables [1]. Esta situación es especialmente acusada en titulaciones de informática y, en particular, en materias como la programación, donde la retroalimentación debe integrar aspectos conceptuales, procedimentales y de diseño, y donde la diversidad de soluciones dificulta una retroalimentación manual sistemática. En este escenario, la irrupción de la inteligencia artificial generativa (IAG), y en particular de los grandes modelos de lenguaje, ha reactivado el interés por formas de retroalimentación automatizada potencialmente escalables y personalizadas [1], [2]. No obstante, su uso introduce un reto pedagógico central: el riesgo de que los estudiantes deleguen el juicio sobre el conocimiento recibido, aceptando respuestas en lugar de tratarlas como hipótesis que deben verificarse y justificarse, lo que puede interpretarse como un debilitamiento de la verificación activa [3]. En consecuencia, el valor formativo del *feedback* depende no solo de su disponibilidad, sino también de cómo el estudiante regula el conocimiento recibido y aplica criterios al utilizarlo [4], [5]. En este contexto, el debate académico se ha centrado fundamentalmente en cuestiones tales como la calidad pedagógica del *feedback*, condiciones de integración en diseños reales, comparación con fuentes humanas y retos éticos y prácticos. Una referencia clave es la revisión sistemática presentada en [6], que identifica beneficios como la inmediatez y la frecuencia del *feedback*, pero también limitaciones recurrentes: variabilidad en la calidad, fuerte dependencia del diseño de *prompts* y necesidad de mantener la supervisión docente como parte del proceso formativo. En la misma línea, estudios comparativos

muestran que el *feedback* con IAG, en tareas de escritura argumentativa en educación superior, puede ser útil en dimensiones como alineamiento con criterios [7] y consistencia frente a *peer feedback* [8], aunque su eficacia depende tanto de la calidad del contenido como de la credibilidad atribuida a la fuente y la disposición del estudiante para usarlo [9]. Más allá de comparar fuentes, otros trabajos analizan qué características del diseño instruccional hacen que el *feedback* con IAG funcione mejor. En [10] se muestra que la orientación del *feedback* (centrado en la tarea, en las ideas o en el proceso) modula tanto la interacción como los resultados, sugiriendo que no existe un “*feedback* universal” con IAG. Desde una mirada aún más procedimental, en [11] se destaca que la utilidad del *feedback* generado con IAG depende de competencias del estudiante para formular solicitudes productivas y evaluar críticamente las respuestas, lo que desplaza la atención desde la herramienta hacia la alfabetización del *feedback* y el diseño de interacción. En esta dirección, [12] muestra que instancias personalizadas (p. ej., GPTs configurados con criterios y guiones) mejoran la utilidad pedagógica del *feedback* en informes de laboratorio al estructurar el diálogo y explicitar criterios; y [13] refuerza el papel complementario de la IAG incluso en tareas avanzadas, siempre bajo mediación humana. En conjunto, todos estos trabajos sugieren que el valor educativo de la IAG como *feedback* aumenta cuando se orienta al proceso y se articula mediante criterios y guiones de interacción, de modo que el estudiante debe interpretar, contrastar y justificar su incorporación. Al mismo tiempo, trabajos de revisión como el presentado en [14] advierten que la integración educativa de *Large Language Models* (LLM) plantea retos que no pueden obviarse (fiabilidad, transparencia, privacidad y responsabilidad) y subrayan la necesidad de diseños pedagógicos responsables centrados en el aprendizaje, la autoría y la capacidad de decisión del estudiante. En definitiva, la cuestión no es solo “si” la IAG puede producir retroalimentación, sino “cómo” debe integrarse para sostener un uso crítico y responsable. Para abordar esta preocupación —evitar la delegación del juicio y sostener la verificación activa—, el estudio adopta el control epistemológico como lente interpretativa para valorar la calidad del uso del *feedback* generado por IAG. Bajo este enfoque, el interés se centra en cómo el estudiante evalúa, contrasta e incorpora en su propio trabajo la retroalimentación recibida. Desde esta perspectiva, la verificación activa y el mantenimiento de una decisión final justificada pueden entenderse como componentes funcionales del control epistemológico, sostenidos por procesos metacognitivos de monitorización y regulación. A la luz de lo mencionado anteriormente, nuestra intervención adopta un enfoque de *feedback* orientado al proceso y guiado por un diseño instruccional, con la IAG en un papel complementario y sin desplazar la decisión final del estudiante: se articula como un ciclo trazable de mejora (pedir–evaluar–decidir–documentar). Este planteamiento resulta especialmente interesante en dominios como la programación, donde la evidencia aún es menor que en tareas de escritura académica y donde el *feedback* debe abordar simultáneamente conceptos, procedimientos y decisiones de diseño.

En consonancia, este trabajo presenta el diseño e implementación de una intervención replicable en una asignatura de programación que integra la IAG como retroalimentación mediante un protocolo de interacción orientado a objetivos, requisitos de trazabilidad (diálogo, decisiones y cambios) y límites de uso y transparencia de autoría, todo ello incorporado en los materiales de la asignatura. Con este fin, el artículo plantea tres metas conectadas:

1. Describir con precisión el paquete de intervención para facilitar su reproducibilidad.
2. Caracterizar patrones de uso de la IAG como retroalimentación a partir del corpus de prácticas encadenadas.
3. Discutir, a la luz de estos patrones y de los indicadores de desempeño, condiciones de adopción, transferibilidad y limitaciones en contextos universitarios con alta carga docente.

El resto del artículo se organiza como sigue: en el Apartado II se describe el contexto de aplicación y el diseño de la intervención, incluyendo los elementos recurrentes del protocolo que guían la interacción con IAG, las fuentes de evidencia y el procedimiento de recogida. El Apartado III presenta los resultados, combinando un análisis descriptivo y un análisis cualitativo longitudinal de los informes de un conjunto de prácticas guiadas, así como la exploración de asociaciones con el desempeño en el proyecto final. Finalmente, en el Apartado IV se discuten los hallazgos a la luz del marco teórico y de las limitaciones del estudio. El Apartado V recoge las conclusiones y las principales líneas de trabajo futuro.

II. METODOLOGÍA

En este apartado se describe el contexto de aplicación, la muestra y la disponibilidad de evidencias (informes de prácticas y nota del proyecto final). A continuación, se detalla el diseño e implementación de la intervención y las fuentes de evidencia, incluyendo el protocolo recurrente de interacción con IAG y los mecanismos de trazabilidad del proceso. Seguidamente, se presenta el esquema de codificación cualitativa —indicadores y reglas de clasificación— del que deriva una taxonomía de tres categorías como indicador de evolución (E, E– y sin etiqueta E/E–) explicada en el apartado II-E. Por último, se describe el uso del proyecto final como medida de desempeño y el plan de análisis.

II-A. Contexto de implementación y participantes

Como caso de estudio, la intervención se implementó en la asignatura de Programación Orientada a Objetos (POO) de un grado de ingeniería informática. Se trata de una materia obligatoria, con docencia eminentemente práctica, orientada al desarrollo progresivo de competencias de análisis, diseño e implementación de software. La población de referencia fue la cohorte matriculada ($N = 70$; 55 hombres, 15 mujeres), organizada en un formato de trabajo continuado basado en una secuencia de prácticas de laboratorio guiadas, ejercicios teórico-prácticos y un proyecto final integrador. Las prácticas guiadas y los ejercicios eran de carácter opcional y su realización era

individual; en cambio, el proyecto final, diseñado para desarrollarse en equipos de dos estudiantes, era obligatorio y actuaba como evidencia integradora del aprendizaje. La intervención se desplegó a lo largo de todo el curso: comenzó con una fase inicial de dos meses y medio, coincidente con las prácticas guiadas del corpus de análisis, y se mantuvo después como marco de trabajo durante el resto del itinerario teórico-práctico y el proyecto final. Dado el carácter opcional de las prácticas guiadas, no todos los estudiantes entregaron la secuencia completa P1–P5 y, de aquellos que lo hicieron, no todos presentaron el proyecto final. Por tanto, el análisis se realizó sobre la muestra con entregas completas: 57 estudiantes para el análisis longitudinal de prácticas guiadas y 55 para el proyecto final. Esto permitió caracterizar de forma temprana (antes del proyecto final) trayectorias longitudinales de uso de la IAG como retroalimentación y explorar, de forma descriptiva, su relación con el desempeño en una tarea integradora. Dado el carácter observacional del estudio y la disponibilidad parcial de evidencias, las asociaciones exploradas se interpretan con cautela.

II-B. Diseño de la intervención y fuentes de evidencia

Se adoptó un diseño de intervención orientado a la mejora iterativa y a la documentación: la IAG se introdujo como fuente de retroalimentación integrada en las tareas ordinarias de la asignatura, con el objetivo de aumentar la frecuencia del *feedback*, su trazabilidad y su utilidad para la revisión del propio trabajo, manteniendo la autoría en el estudiante y promoviendo el contraste crítico con materiales del curso. El diseño se concretó en dichas tareas, con apoyos instruccionales progresivos, una plantilla de informe que exige evidencias del proceso (*prompts*, respuestas relevantes, decisiones de aceptación/rechazo y reflexión) y un taller breve de *prompting* que aporta un guion común para solicitar evaluación formativa. Las fuentes de evidencia que se utilizan en este estudio, son parte de ese trabajo: (a) informes de P2–P5, que incluyen evidencias de interacción con la IAG, justificación de cambios y declaración de autoría, y (b) la calificación del proyecto final, entendida como síntesis integradora de competencias de POO. Estas evidencias no sustituyen la evaluación docente, sino que permiten describir longitudinalmente patrones de uso del *feedback* y su posible relación con el desempeño. Para explorar posibles desequilibrios en el uso de la IAG, se utilizó el género registrado (hombres $n = 44$; mujeres $n = 13$) para describir la distribución de las etiquetas (E, E– y sin etiqueta E/E–) y realizar contrastes exploratorios. En términos de transparencia y autoría, los requisitos se integraron en los enunciados y en la plantilla de informe, exigiendo declarar qué parte del trabajo es personal, qué sugerencias se aplican o se descartan y por qué, y cualquier otro uso puntual de la IAG.

II-C. Diseño e implementación de las prácticas guiadas y requisitos de evidencia

Las prácticas guiadas se organizaron como un itinerario P1–P5 encadenado y de complejidad creciente, en el que cada entrega genera un documento comparable (código + autoevaluación + retroalimentación con IAG + trazabilidad) apto para

análisis longitudinal. Todas las prácticas comparten una estructura estable: (i) objetivos de aprendizaje explícitos, (ii) desarrollo guiado por partes sobre una base de código en *Java* que se hereda y extiende, (iii) rúbrica de logro y preguntas de autoevaluación que obligan a justificar decisiones con evidencias del propio código, (iv) una fase final de retroalimentación con IAG en la que el estudiante solicita una evaluación formativa (no numérica) aportando en el *prompt* el enunciado, objetivos, rúbrica, código y respuestas, con posibilidad de iteración del *prompt* hasta obtener *feedback* factible, y (v) entrega mediante un informe en PDF que incluye el desarrollo completo, la transcripción del diálogo con la IAG, una valoración crítica de utilidad/limitaciones y una declaración de autoría y uso de IAG con decisiones de aceptación/rechazo justificadas. Esta pauta común reduce la variabilidad entre entregas y hace que P2–P5 constituyan un corpus homogéneo y evaluable, mientras que P1 (que queda fuera del análisis longitudinal) actúa como práctica de arranque para familiarizarse con el formato de entrega y la dinámica de revisión.

En cuanto al contenido, el itinerario P1–P5 se diseñó como una progresión encadenada de complejidad creciente sobre una base de código reutilizado entre prácticas, cubriendo bloques nucleares de POO. En este sentido, P1 actúa como práctica de arranque (fundamentos de POO, p. ej., clase vs. objeto, atributos/métodos y encapsulación, junto con el formato y la dinámica de entrega) y P2–P5 constituyen el corpus analizado: (i) herencia y polimorfismo, (ii) contratos mediante interfaces y una arquitectura mínima de interacción, (iii) extensibilidad y uso de bibliotecas estándar, y (iv) robustez y calidad mediante programación defensiva y documentación con *diseño por contrato* (pre/postcondiciones e invariantes). Esta progresión ha permitido observar, de forma comparable entre entregas, la estabilización (o no) de conductas indicativas de control epistemológico en el uso de la IAG como retroalimentación.

Como salvaguarda pedagógica, los enunciados insisten en que la IAG se debe emplear únicamente para retroalimentación y sugerencias de mejora sobre trabajo ya realizado (código y respuestas), prohibiendo su uso para la elaboración inicial; además, se recomienda contrastar la retroalimentación con materiales de clase u otras fuentes fiables y consultar al profesorado ante dudas persistentes.

II-D. Protocolo recurrente de interacción con IAG y trazabilidad

Dado que los enunciados de P1–P5 incorporan de forma sistemática un mismo módulo de orientación para usar la IAG como retroalimentación y documentar la autoría, en la Tabla I se explicita su redacción operativa.

Este módulo aparece en todas las prácticas guiadas (con ajustes menores de numeración y ejemplos), y se apoya en la plantilla de informe para garantizar trazabilidad y comparabilidad longitudinal. El módulo combina un guion para solicitar retroalimentación, un informe de trazabilidad del diálogo y un bloque de uso responsable que limita la IAG a la revisión del trabajo ya realizado y exige una declaración explícita de autoría y uso.

TABLA I
ELEMENTOS RECURRENTES PARA GUIAR LA INTERACCIÓN CON IAG Y
DOCUMENTAR AUTORÍA

Elemento recurrente	Redacción operativa (requisitos)
Guía para obtener retroalimentación de la IAG (enunciado)	El <i>prompt</i> debe incluir, como mínimo: (a) el enunciado de la práctica, (b) los objetivos de aprendizaje, (c) la rúbrica de logro, (d) el código desarrollado y (e) las preguntas de autoevaluación con sus respuestas. La retroalimentación solicitada debe evitar notas numéricas y estructurarse en: qué está bien resuelto, qué errores o carencias se detectan, qué es mejorable y si se han alcanzado los objetivos (en código y respuestas). Si la respuesta no es clara o útil, el estudiante debe refinar el <i>prompt</i> añadiendo contexto, ejemplos o aclaraciones.
Informe y trazabilidad del diálogo (plantilla de informe)	El informe en PDF debe incluir la transcripción íntegra y ordenada del diálogo (<i>prompts</i> y respuestas), junto con una valoración personal sobre utilidad y limitaciones de la retroalimentación y qué mejoras se incorporarán (si procede), reflexionando sobre su impacto en el aprendizaje y la transferencia a prácticas posteriores.
Transparencia de uso (declaración de uso de IAG) (enunciado + plantilla)	El uso de IAG se permite únicamente para obtener retroalimentación y sugerencias de mejora sobre trabajo ya realizado (p. ej., auditoría de código o propuestas de corrección), y se prohíbe la elaboración inicial de código, respuestas o informes mediante IAG. La plantilla exige declarar: (a) qué partes del trabajo son originales del estudiante, (b) qué mejoras se incorporaron o se descartaron tras el <i>feedback</i> y por qué, y (c) cualquier otra intervención relevante de la IAG en el proceso de revisión.

II-E. Etiqueta longitudinal de evolución como indicador de progreso

Como indicador cualitativo para valorar el alcance del impacto de la intervención en el uso formativo de la IAG, se codificó el análisis longitudinal de evolución mediante una etiqueta longitudinal (E, E- o sin etiqueta E/E-), asignada a cada estudiante en función de su trayectoria de aprendizaje observada a lo largo de P2-P5. Esta etiqueta funciona como indicador de progreso y, a la vez, como indicador complementario del control epistemológico. En línea con marcos de cognición y desempeño epistémico, el control epistemológico se entiende como la capacidad de regular activamente el conocimiento recibido —tratándolo como hipótesis falible—, aplicar criterios explícitos, justificar decisiones de adopción/rechazo y desplegar procesos fiables de evaluación antes de integrarlo en el propio trabajo [4], [15], [16], [17]. En el caso de la IAG, esta regulación resulta especialmente relevante para garantizar la verificación activa y evitar la delegación de juicio en la herramienta [3]. En este trabajo, este esquema se concreta en tres indicadores observables en los informes:

- Iteración: presencia recurrente de ciclos de diálogo con IAG (p. ej., refinamiento de *prompts* y nuevas consultas tras evaluar respuestas), con trazabilidad de los cambios entre iteraciones (qué se modifica y por qué). Se interpreta como señal de regulación del proceso de búsqueda y depuración de *feedback* [6], [11], [12].

- Metacognición: explicitación de criterios de aceptación/rechazo (p. ej., plausibilidad, consistencia, etc), apoyada en evidencias de contraste y justificación [15], [16], [17], [18], incluyendo la reflexión sobre qué se ha comprendido o ajustado en el propio enfoque. Incluye decisión justificada y mención básica del papel desempeñado por la IAG como indicador de autonomía.
- Transferencia: reutilización y adaptación consciente, en prácticas posteriores, de aprendizajes o estrategias previamente empleadas (p. ej., criterios de evaluación, estructura de *prompts* o pasos de verificación), mostrando continuidad y estabilidad del enfoque [4], [17]. Se consideró clave explicitar qué elemento se reutiliza, de dónde proviene y cómo se adapta al nuevo contexto.

Con estos indicadores, se definieron tres categorías:

- Etiqueta E (evolución consolidada): evidencia sostenida de los indicadores anteriores a lo largo del ciclo (P2-P5), con mejora consistente en el modo de interacción con la IAG y su integración como retroalimentación.
- Etiqueta E- (evolución en transición no consolidada): mejora observable pero incompleta; alguno de los indicadores aparece de forma débil, episódica o no sostenida en el ciclo.
- Sin etiqueta E/E-: ausencia de evidencias consistentes de consolidación de los indicadores a lo largo del ciclo; el uso de la IAG se mantiene predominantemente lineal o instrumental, sin trazas suficientes de iteración, metacognición o transferencia para asignar E o E-.

A nivel interpretativo, las etiquetas E y E- se consideran indicadores sintéticos de una trayectoria compatible con un mayor control epistemológico en la práctica, al reflejar (en distinto grado) la progresión y estabilización de conductas observables. En cambio, “sin etiqueta E/E-” agrupa los casos sin evidencia suficiente para sostener esa interpretación. La trazabilidad del proceso (p. ej., declaración de uso de IAG y documentación de decisiones) se empleó como soporte metodológico para interpretar esas conductas, sin constituir una dimensión adicional del esquema de codificación.

II-F. Medida de desempeño académico: proyecto final

Además del análisis cualitativo longitudinal de P2-P5, se utilizó el proyecto final como medida de desempeño académico para estimar la transferencia de los aprendizajes a una tarea integradora. El proyecto consistió en la implementación, en *Java* y sin interfaz gráfica ni persistencia, de un sistema de gestión básico (p. ej., tienda: productos, clientes y pedidos), con reglas de negocio explícitas (por ejemplo, stock nunca negativo y verificación agregada por producto al confirmar pedidos), y con énfasis en diseño orientado a objetos, programación defensiva y calidad del código. El enunciado incorporó objetivos de aprendizaje detallados (modelado OO desde narrativa, aplicación de principios de diseño (p. ej., SOLID), uso con criterio de patrones abordados, calidad de implementación, pruebas

mediante una *Smoke class* y documentación mínima útil con *JavaDoc*), así como requisitos funcionales y validaciones, de modo que el desempeño reflejara decisiones de diseño y calidad del proceso, y no únicamente corrección funcional. En coherencia con las prácticas guiadas, el proyecto final pautó el uso de IAG en dos fases: (i) retroalimentación sobre el diseño (incluyendo el diagrama de clases y una auditoría de responsabilidades y reglas del dominio) y (ii) retroalimentación sobre la implementación (código *Java* y respuestas), usando la rúbrica como marco organizador del *feedback*. Se mantuvo el principio de uso posterior al trabajo propio y la recomendación de iterar y contrastar las sugerencias antes de incorporarlas. El proyecto final se inició con parejas asignadas aleatoriamente; los casos individuales corresponden a parejas que quedaron incompletas por abandono de un miembro. En los equipos de dos estudiantes, la calificación fue compartida y se asignó según la declaración explícita en el informe de un reparto equilibrado de tareas; por ello, la nota se interpreta como desempeño del equipo. En este trabajo, la calificación del proyecto final se emplea como indicador global de desempeño académico para explorar asociaciones con las trayectorias longitudinales observadas en P2–P5 (E, E– o sin etiqueta E/E–).

II-G. Plan de análisis

A partir del esquema de codificación descrito en los apartados anteriores, el análisis se articuló en dos niveles: (i) la caracterización longitudinal del corpus P2–P5 en la muestra con secuencia completa ($N = 57$) y (ii) la exploración cuantitativa de asociaciones con el desempeño en el proyecto final en la submuestra con calificación disponible ($N = 55$). Para reforzar la consistencia del proceso, se incorporó una comprobación de fiabilidad intercodificador mediante recodificación independiente de una submuestra y estimación del acuerdo (κ de Cohen). Además, en el subgrupo con etiqueta E– se examinó el indicador menos consolidado (iteración, metacognición o transferencia) como aproximación descriptiva a los puntos frágiles del uso formativo. En el análisis del proyecto final se consideró la estructura de equipos (31 equipos) y, dado que la calificación es compartida, los contrastes se realizaron a nivel de equipo. Para reducir sesgos de confirmación, se aplicó un protocolo de codificación ciega bidireccional: la codificación cualitativa de P2–P5 se realizó sin acceso a las calificaciones y, de forma complementaria, el procesamiento de las calificaciones y su análisis descriptivo inicial se efectuó antes de incorporar la etiqueta longitudinal derivada de las prácticas guiadas. La trayectoria del equipo se operativizó como presencia de E/E– (“con E/E–” si al menos un miembro presenta E o E–; “sin E/E–” en caso contrario; en individuales coincide con la etiqueta). Dado que esta etiqueta se infiere en P2–P5, su relación con la nota del proyecto final (al cierre del curso) se analiza como una asociación entre un indicador temprano y un resultado posterior. Esta relación se exploró mediante métodos no paramétricos (Mann–Whitney), reportando tamaños de efecto e interpretando los resultados como evidencia exploratoria, sin inferencia causal. Como análisis de sensibilidad, (i) se repitieron los contrastes restringiéndolos a parejas y (ii) se describieron por separado los casos individuales.

Asimismo, dentro de los equipos con E/E– se comparó el máximo del equipo (E vs E–) respecto a la nota. Finalmente, se realizaron análisis descriptivos estratificados por género, con carácter exploratorio y atendiendo a brechas observadas en estudios previos del mismo contexto docente [19]; estos análisis se interpretan con cautela por el desequilibrio muestral y la ausencia de control de covariables.

III. RESULTADOS DEL ANÁLISIS

En este apartado se presentan los resultados del análisis de las evidencias de P2–P5 y, en la submuestra con calificación, del proyecto final. Primero se reportan los hallazgos del análisis longitudinal (distribución de etiquetas e indicadores). Después se describen los patrones del grupo E– y la lectura desagregada por género. Por último, se presentan los análisis exploratorios de asociación entre la presencia de E/E– y la nota del proyecto final.

III-A. Resultados globales: etiquetas longitudinales e indicadores de desempeño

La Tabla II sintetiza la distribución de etiquetas longitudinales E, E– y sin etiqueta E/E– (evolución observada a lo largo de P2–P5) en el grupo completo ($n = 57$). En términos globales, casi la mitad del grupo aparece sin etiqueta E/E– (49,1%, 28/57), mientras que el resto se reparte entre E– (31,6%, 18/57) y E (19,3%, 11/57).

TABLA II
DISTRIBUCIÓN DE ETIQUETAS LONGITUDINALES DE EVOLUCIÓN (E, E–, SIN ETIQUETA E/E–) EN EL CONJUNTO DEL GRUPO ($N = 57$).

Etiqueta	Total	%
E	11	19,3
E–	18	31,6
Sin E/E–	28	49,1

Esta distribución sugiere que, aunque una parte relevante del alumnado muestra señales de cambio a lo largo de las prácticas, existe también un contingente amplio cuyo patrón de uso no evidencia progresión suficiente para ser etiquetado longitudinalmente. Puesto que estas etiquetas se derivan de un proceso de codificación cualitativa, se verificó su consistencia mediante acuerdo intercodificador. En la submuestra doble-codificada ($n = 25$ de 57), el acuerdo fue sustancial ($\kappa = 0,75$; 84,0% de acuerdo, 21/25). Las discrepancias se concentraron exclusivamente en la frontera entre las categorías E– y sin etiqueta E/E–, sin afectar a la categoría E, lo que sugiere discrepancias en casos límite.

En la Tabla III, el análisis del subgrupo con etiqueta E– ($n = 18$) del indicador menos consolidado entre iteración, transferencia y metacognición muestra un patrón claro: la iteración es, con diferencia, el indicador que con mayor frecuencia no se estabiliza (12/18; 66,7%), mientras que transferencia y metacognición aparecen como indicador débil en una proporción menor (3/18; 16,7% cada una). Este resultado sugiere que, incluso cuando se observan avances parciales en el uso de la IAG, el principal cuello de botella en E– reside en sostener ciclos iterativos de interacción de forma consistente a lo largo de P2–P5. Por otro lado, en el subgrupo sin etiqueta E/E– no se

observan señales consistentes de consolidación de ninguno de estos indicadores, lo que apunta a un patrón más instrumental o lineal.

TABLA III
INDICADOR MENOS CONSOLIDADO EN EL SUBGRUPO E- (N = 18)

Indicador	Total	%
Iteración	12	66,7
Transferencia	3	16,7
Metacognición	3	16,7

III-B. Análisis desagregado por género

Con el fin de explorar posibles diferencias de participación y trayectorias, se estratificaron los indicadores cualitativos por género. En la Tabla IV se presenta la distribución de etiquetas (E, E- y sin etiqueta E/E-) como indicadores de impacto para explorar posibles diferencias entre los dos subgrupos.

TABLA IV
DISTRIBUCIÓN DE ETIQUETAS LONGITUDINALES POR GÉNERO (N = 57)

Etiqueta	Hombres (n=44)	%	Mujeres (n=13)	%
E	7	15,9	4	30,8
E-	12	27,3	6	46,2
Sin E/E-	25	56,8	3	23,1
Total	44	100,0	13	100,0

Las mujeres muestran mayores proporciones de etiquetas E o E- (77,0%) que los hombres (43,2%), lo que sugiere, en esta muestra y con las limitaciones del desequilibrio muestral, mayor frecuencia de uso regulado/formativo de la IAG. En la Tabla V se presentan los resultados del subgrupo con etiqueta E-, desagregados por género (12 hombres y 6 mujeres).

TABLA V
INDICADOR MENOS CONSOLIDADO EN EL SUBGRUPO E- POR GÉNERO

Indicador	Género	Total	%
Iteración	Hombre	6	33,3
	Mujer	6	33,3
Transferencia	Hombre	3	16,7
	Mujer	0	0
Metacognición	Hombre	3	16,7
	Mujer	0	0

En el caso de las mujeres, el indicador menos consolidado es la iteración (6/6; 100%), mientras que en hombres la menor consolidación se distribuye entre iteración (6/12; 50%), transferencia (3/12; 25%) y metacognición (3/12; 25%). Todos estos patrones deben interpretarse como indicios y no como diferencias concluyentes dado el desequilibrio muestral.

III-C. Análisis cualitativo: patrones de control epistemológico en el uso de IAG

El análisis cualitativo longitudinal de los informes P2-P5 permite identificar patrones discursivos y conductuales que caracterizan el control epistemológico en el uso de IAG, entendido como la capacidad del estudiante para formular *prompts* orientadas a objetivos, evaluar críticamente las respuestas como hipótesis falibles, decidir con criterios explícitos qué aceptar o rechazar y regular el proceso de mejora mediante iteración, metacognición y transferencia entre prácticas.

Este marco se alinea con la definición metodológica de las etiquetas longitudinales (E, E- y sin etiqueta E/E-), utilizadas aquí como síntesis de la trayectoria observada a lo largo del ciclo. En los casos clasificados con etiqueta E (y, en menor medida, E-), la IAG aparece de forma consistente como un recurso para contrastar decisiones y regular el desarrollo, más que como una fuente de soluciones finales. Un patrón recurrente es la descomposición deliberada del problema y la interacción por fases, visible en fragmentos del tipo “*en vez de en un texto toda la consulta, ir pidiendo poco a poco*”, lo que sugiere iteración y control conversacional. Asimismo, se observan criterios explícitos de aceptación/rechazo, por ejemplo cuando el estudiante declara haber “*he descartado mejoras que se salían fuera del enunciado...*”, señal de que el *feedback* se filtra atendiendo a restricciones del dominio (requisitos, diseño previsto o alcance de la práctica). En conjunto, estos indicios apuntan a procesos metacognitivos de monitorización y regulación: el estudiante evalúa la pertinencia del *feedback* y decide cómo incorporarlo sin delegar el juicio final. De forma más explícita, varias respuestas caracterizan la IAG como herramienta de apoyo a la reflexión más que de generación directa de código: “*Más que darme código, me ha servido como herramienta para analizar y revisar mis decisiones de diseño...*”. Este tipo de formulaciones metacognitivas, presentes en los casos con etiqueta E o E-, reflejan capacidad de decisión y control, en tanto el estudiante mantiene la decisión final y justifica la adopción o rechazo de las sugerencias. Asimismo, esta reflexión puede referirse al propio proceso (“*fomentándome un enfoque más metódico y reflexivo hacia el desarrollo...*”) y coexistir con señales explícitas de transferencia hacia prácticas posteriores, por ejemplo: “*En próximas prácticas quiero mejorar la documentación con diseño por contrato...*” o, de forma aún más directa entre prácticas, “*...en las siguientes prácticas me fijo en los errores cometidos anteriormente para no volverlo a hacer*”. Estas evidencias sugieren que el control epistemológico no es un episodio aislado, sino un patrón sostenido de regulación: se aprende a preguntar mejor, a revisar con mayor profundidad y a incorporar criterios como parte estable del flujo de trabajo. En contraste, en los casos sin etiqueta E/E- se observa con mayor frecuencia un uso más lineal y operativo, centrado en eficiencia o desbloqueo puntual. Aparecen formulaciones que enfatizan el ahorro de tiempo (“*Me ha ahorrado muchísimo tiempo de estar poniendo la documentación...*”) o el “refresco” conceptual (“*Me ha refrescado el concepto de la comparación mediante Strings...*”) sin acompañarse de evidencias claras de contraste, pruebas o criterios de aceptación. Del mismo modo, la ausencia de iteración (“*una sola pregunta...*”) sugiere un patrón de consulta única seguida de implementación directa, donde el estudiante regula menos el proceso y, por tanto, reduce las oportunidades de verificación crítica. En algunos casos, también se detectan indicios de baja regulación del alcance (“*mejoras de más que no pido...*”), lo que puede interpretarse como dificultad para reconducir la interacción con límites y objetivos explícitos. En conjunto, estos patrones cualitativos aportan evidencia directa sobre el proceso: el corpus P2-P5 muestra diferencias sustantivas en cómo se usa la IAG como retroalimentación, desde un uso reactivo

orientado al resultado hasta un uso regulado que incorpora contraste crítico, iteración y toma de decisiones.

III-D. Asociaciones entre etiquetas de trayectoria y desempeño académico en el proyecto final

En la submuestra con calificación del proyecto final (N = 55; 31 equipos: 24 parejas y 7 casos individuales), se exploró la relación entre desempeño académico y trayectorias cualitativas (etiquetas E/E- derivadas del análisis longitudinal de P2–P5). Dado que la calificación de este proyecto es compartida por el equipo, los contrastes se realizaron a nivel de equipo. La trayectoria se codificó de forma dicotómica: "con E/E-" si al menos un integrante presentaba etiqueta E o E-, "sin E/E-" en caso contrario. En los trabajos individuales, la clasificación coincide con la etiqueta del estudiante. En la Tabla VI se muestran los resultados del análisis.

TABLA VI
DESEMPEÑO EN EL PROYECTO FINAL EN FUNCIÓN DE LA PRESENCIA DE E/E- (ANÁLISIS A NIVEL DE EQUIPO, PAREJAS E INDIVIDUALES)

Distribución	Grupos	N	Med	U	p	g
Equipos (31)	con E/E-	19	8,90	165	0,040	0,87
	sin E/E-	12	8,05			
Parejas (24)	con E/E-	15	9,00	106	0,023	1,10
	sin E/E-	9	8,00			
Individuales (7)	con E/E-	4	7,6	4,5	0,857	0,04
	sin E/E-	3	8,1			

Para facilitar la interpretación de esta tabla y de las que vienen a continuación indicar que “Med” denota la mediana de la nota del proyecto y “U” el estadístico de Mann–Whitney, “g” representa el tamaño de efecto (Hedges), y “Composición” indica la combinación de etiquetas dentro de la pareja. A nivel de equipo, aquellos con presencia de E/E- obtuvieron medianas superiores a los equipos sin E/E-, con diferencias significativas en Mann–Whitney (U = 165, p = 0,040) y un tamaño de efecto grande (g = 0,87). Este patrón se mantuvo al restringir el análisis al subconjunto de parejas (U = 106, p = 0,023; g = 1,10). En los 7 trabajos individuales, no se observaron diferencias entre quienes presentan etiqueta E o E- y quienes no (U = 4,5; p = 0,857), aunque la nota en ambos casos es manifiestamente menor con respecto a las notas obtenidas por equipos de parejas. Estos resultados deben interpretarse con cautela debido al tamaño muestral reducido que limita la potencia estadística del contraste. De forma complementaria, se exploró si dentro de las parejas con presencia de E o E-, disponer de una etiqueta máxima E (frente a E-) se asociaba con una nota superior (Tabla VII). No se observaron diferencias significativas en la nota entre parejas con máximo E y máximo E-.

TABLA VII
DESEMPEÑO EN EL PROYECTO FINAL DENTRO DE EQUIPOS CON PRESENCIA DE ETIQUETAS E/E- SEGÚN LA ETIQUETA MÁXIMA DEL EQUIPO (E VS E-)

Grupo	Etiqueta	N	Med.	U	p
Parejas E/E-	E	9	9,00	23	0,689
	E-	6	9,05		

Por otro lado, al desglosar la composición interna de las parejas con presencia de E/E-, no se aprecia un patrón adicional consistente, con tamaños muestrales reducidos (Tabla VIII).

TABLA VIII
MEDIANA DE LA NOTA DEL PROYECTO SEGÚN LA COMPOSICIÓN DE ETIQUETAS EN PAREJAS CON PRESENCIA DE E/E-

Composición de la pareja	N	Med.	U	p
E + E/E-	5	8,95	7	0,556
E + sin E/E-	4	9,15		
E- + E-	4	9,03	4	1,000
E- + sin E/E-	2	9,05		

IV. DISCUSIÓN DE LOS RESULTADOS DEL ANÁLISIS

Los hallazgos apuntan a que el impacto de la IAG como retroalimentación depende menos de la herramienta en sí y más del guion pedagógico que estructura la interacción y obliga a producir evidencia del proceso (diálogo, decisiones y cambios) [1], [2]. Desde esta perspectiva, el hilo conductor de la discusión es el diseño de la intervención y su traducción a prácticas docentes replicables. Integrar IAG como retroalimentación en programación implica diseñar un proceso trazable de mejora —pedir, interpretar, contrastar, decidir y documentar— sin desplazar la autoría del estudiantado. Para ello se combinaron prácticas guiadas con complejidad creciente (P2–P5), un taller de *prompting* y un protocolo recurrente de interacción. Los resultados muestran una adopción heterogénea, coherente con la variabilidad descrita en la literatura sobre la calidad del *feedback* generado por LLM en función de la formulación de *prompts*, el encuadre de la tarea y las competencias del estudiante para evaluar respuestas [6], [7].

En esta cohorte, las etiquetas longitudinales sugieren que una parte del estudiantado progresa hacia un uso formativo regulado (E o E-), mientras que otra mantiene un patrón funcional o instrumental sin señales consistentes de iteración, contraste y transferencia. En términos de mecanismo, los informes P2–P5 permiten distinguir dos formas de relación con la IAG: (i) un uso regulado, donde la herramienta opera como auditor o revisor y el estudiante mantiene el control de la decisión final (iteración, contraste, criterios explícitos y justificación), y (ii) un uso más lineal o delegativo, donde la IAG se usa como fuente de respuesta con escasa verificación y poca transferencia entre tareas. Esta dicotomía es consistente con trabajos que subrayan la necesidad de guiar el diálogo para promover elaboración, verificación y refinamiento del *feedback* [2], [8], [9], [11]. Dentro del perfil E-, el análisis del indicador menos consolidado muestra que el principal punto frágil es sostener la iteración como ciclo estable a lo largo de P2–P5, más que la mera presencia puntual de criterios o reflexiones. Este resultado sugiere la necesidad de intervenciones para este perfil: mínimos verificables de iteración (p. ej., exigir una segunda ronda documentada de refinamiento del *prompt* y la justificación explícita del cambio), con baja carga y alta trazabilidad [1]. Estos patrones son consistentes con el marco de control epistemológico adoptado [4], [15], [16], [17]: el conocimiento externo (en este caso, *feedback* generado por IAG) debe tratarse como hipótesis falible, someterse a criterios explícitos de validación y ser justificado antes de integrarlo en el trabajo propio. En este sentido, las etiquetas E y E- funcionan como síntesis de progreso hacia el control epistemológico en práctica, especialmente relevante en IAG para sostener la verificación activa y evitar tratar la herramienta como autoridad cognitiva [3].

Dado el carácter observacional del estudio, los contrastes con desempeño y los análisis desagregados se interpretan como indicios, sin inferencia causal. De forma complementaria, la exploración con la nota del proyecto final, agregada a nivel de equipo, ofrece un indicio alineado con la hipótesis de transferencia: la presencia de etiqueta E o E- se asocia con mejores calificaciones. Conviene matizar, además, la naturaleza temporal de este indicio: las etiquetas E/E- se derivan del análisis longitudinal de P2 - P5, correspondiente a la fase inicial de la intervención ($\approx$ dos meses y medio), mientras que la calificación del proyecto final se obtiene al cierre de la asignatura.

En este sentido, la etiqueta no pretende describir el estado “final” del estudiante, sino un indicador temprano de adopción de un patrón de regulación; por ello, quienes lo muestran antes tienden a rendir mejor al final. Aun así, no puede descartarse que algunas trayectorias cambien durante el tramo final del curso y el propio proyecto, lo que introduce incertidumbre sobre la estabilidad de la clasificación y puede estar influido tanto por la variación de las trayectorias en la fase final como por diferencias previas de motivación, madurez académica o competencias de base [5].

Además, al comparar equipos (formados por parejas de estudiantes) “liderados” por E frente a E- (máximo del equipo), no se observaron diferencias en la nota. Este resultado es coherente con la naturaleza del proyecto: se trata de un trabajo compartido cuya calificación refleja el producto conjunto y, por tanto, depende de la contribución y coordinación de ambos miembros. En clave positiva, el trabajo en equipo puede haber facilitado la difusión de prácticas de regulación: si un miembro adopta tempranamente un uso regulado, esas prácticas pueden trasladarse al flujo compartido y favorecer la mejora de compañeros inicialmente menos regulados; esta hipótesis no puede verificarse con las evidencias disponibles (no se recogieron trazas intra-equipo comparables). En consecuencia, una etiqueta individual más alta no se traducirá necesariamente en mayor rendimiento si no se convierte en prácticas compartidas (acuerdos, verificación y refinamiento) y en una ejecución técnica coherente del equipo, dado que la regulación del *feedback* con IAG en el proyecto exige coordinación y validación conjunta.

Finalmente, debido al desequilibrio muestral y a la ausencia de control de covariables, el análisis desagregado por género se interpreta con cautela; en esta cohorte, las mujeres muestran una mayor proporción de etiquetas E/E- que los hombres, lo que sugiere mayor frecuencia de uso regulado/formativo. Dentro del subgrupo E-, la iteración aparece como el componente menos consolidado en mujeres, mientras que en hombres la menor consolidación se reparte entre iteración, transferencia y metacognición.

En conjunto, el estudio sugiere que la intervención funciona como un andamiaje que hace visibles prácticas de evaluación y regulación, pero deja abierta una cuestión central: cómo apoyar al alumnado funcional sin etiqueta E/E- para incorporar mínimos verificables de iteración, contraste y transferencia sin aumentar carga docente ni desplazar autoría

V. CONCLUSIONES Y LÍNEAS FUTURAS DE TRABAJO

Este trabajo presenta el diseño y evaluación inicial de una intervención para integrar IAG como retroalimentación en programación, basada en un encuadre pedagógico explícito y una secuencia de prácticas P2-P5 orientada a promover un uso regulado y transferible. Implementada en una asignatura de programación (POO), la intervención muestra viabilidad en un contexto real de alta carga docente. La contribución principal es un paquete de materiales y un protocolo que convierten el *feedback* con IAG en un proceso trazable. Además, se propone un indicador cualitativo longitudinal (etiqueta de evolución E, E-, sin etiqueta E/E-) como síntesis de conductas observables ligadas al control epistemológico (iteración, metacognición y transferencia) y útil para caracterizar trayectorias de uso formativo. Como evidencia de funcionamiento, el análisis longitudinal revela una adopción heterogénea: algunos perfiles evolucionan hacia un uso regulado (E o E-) y otros mantienen un uso mínimo o lineal. En el proyecto final, la presencia de etiqueta E o E- a nivel de equipo se asocia con mejores calificaciones, en línea con la hipótesis de que el beneficio emerge cuando las prácticas de regulación se convierten en dinámicas compartidas en un producto conjunto; en este marco, el trabajo en equipo podría facilitar la difusión y transferencia de esas prácticas, hipótesis que requiere evidencias intra-equipo. Sin embargo, dado que las etiquetas se derivan de la fase inicial (P2-P5) y no se recalculan durante el proyecto, la asociación con la nota debe leerse como indicio observacional de adopción temprana; por ello, se interpreta como asociación exploratoria y no causal, sin asumir estabilidad del perfil hasta el cierre. En el análisis desagregado por género (también exploratorio por el desequilibrio muestral), se observa una mayor proporción de etiquetas E/E- en mujeres y, dentro del subgrupo E-, la iteración aparece como el componente menos consolidado.

Como líneas futuras, se propone replicar la intervención en próximas cohortes y en otras asignaturas para evaluar generalización y sostenibilidad. También se plantea afinar materiales y despliegue del “guion” para asegurar mínimos verificables (explicitar criterios, iterar y justificar cambios), revisando apoyos realmente usados y puntos de omisión. Para el alumnado sin etiqueta E/E-, se priorizarán medidas de bajo coste: exigir una segunda iteración documentada y, si persisten problemas o el *feedback* es insuficiente, una tercera, ambas con una justificación breve de “qué cambió y por qué” apoyada en ejemplos modelo. Para acotar el desfase temporal entre P2-P5 y el desempeño final, se propone verificar la estabilidad de la etiqueta durante el proyecto mediante evidencias de baja intrusión (trazas del repositorio, hitos y una bitácora mínima de decisiones e iteraciones), estimando si el patrón se mantiene, se consolida o cambia en la fase final. Por último, se mantendrá la vigilancia sobre participación y acceso a estrategias de uso formativo (incluyendo género), incorporando preguntas simples para detectar barreras sin sobredimensionar resultados.

REFERENCIAS

- [1] Joaquín Ballesteros, Pablo Franco, y Lidia Fuentes, “Coevaluando con LLM: generando una retroalimentación formativa a tiempo,” *Actas de las JENUI*, vol. 10, pp. 111–119, Valladolid, Spain, Jul. 2025.
- [2] David García-Solorzano, Nati Cabrera, Carolina García-Londono, María Jesus Marco-Galindo, Julia Minguillon, Carlos Casado-Martínez, Marcelo Fabian Maina, Montse Vall-llovera Llovet, Rosa María Mayordomo, Lourdes Guardia Ortiz, y Robert Clariso, “FeedSmart: una herramienta basada en IA generativa para asistir al profesorado en la elaboración de retroalimentación formativa y personalizada,” *Actas de las JENUI*, vol. 10, pp. 165–173, Valladolid, Spain, Jul. 2025.
- [3] Dan Sperber, Fabrice Clément, Christophe Heintz, Olivier Mascaro, Hugo Mercier, Gloria Origgi, y Deirdre Wilson, “Epistemic vigilance,” *Mind & Language*, vol. 25, no. 4, pp. 359–393, 2010, doi: 10.1111/j.1468-0017.2010.01394.x.
- [4] William A. Sandoval, Jeffrey A. Greene, y Ivar Bråten, “Understanding and promoting thinking about knowledge: Origins, issues, and future directions of research on epistemic cognition,” *Review of Research in Education*, vol. 40, no. 1, pp. 457–496, 2016, doi: 10.3102/0091732X16669319.
- [5] Jeffrey Alan Greene, Brian M. Cartiff, y Rebekah F. Duke, “A meta-analytic review of the relationship between epistemic cognition and academic achievement,” *Journal of Educational Psychology*, vol. 110, no. 8, pp. 1084–1111, 2018, doi: 10.1037/edu0000263.
- [6] Sophia Soomin Lee y Ryan L. Moore, “Harnessing generative AI (GenAI) for automated feedback in higher education: A systematic review,” *Online Learning*, vol. 28, no. 3, pp. 82–104, 2024, doi: 10.24059/olj.v28i3.4593.
- [7] Julia Steiss, Tyler Tate, Steve Graham, Jose Cruz, Matthew Hebert, Jiayan Wang, Yoonjeong Moon, Weijia Tseng, Mark Warschauer, y Carol B. Olson, “Comparing the quality of human and ChatGPT feedback of students’ writing,” *Learning and Instruction*, vol. 91, 101894, 2024, doi: 10.1016/j.learninstruc.2024.101894.
- [8] Seyedeh Kiana Banihashem, Hendrik Drachsler, y Omid Noroozi, “Feedback sources in essay writing: Peer-generated or AI-generated feedback?” *International Journal of Educational Technology in Higher Education*, vol. 21, Article 32, 2024, doi: 10.1186/s41239-024-00455-4.
- [9] Joshua Weidlich, Flurin Gotsch, Kai Schudel, Claudia Marusic-Würscher, Jennifer Mazzarella, Hannah Bolten, Dario Büttler, Simon Luger, Bettina Wohlfender, y Katharina Maag Merki, “Teacher, peer, or artificial intelligence? Comparing effects of feedback sources on students’ learning and writing performance,” *Computers & Education Open*, vol. 9, 100300, 2025, doi: 10.1016/j.caeo.2025.100300.
- [10] Shen Ba, Yidan Zhan, Long Huang, y Guosong Lu, “Investigating the impact of ChatGPT-assisted feedback on the dynamics and outcomes of online inquiry-based discussion,” *British Journal of Educational Technology*, vol. 56, no. 5, pp. 1710–1734, 2025, doi: 10.1111/bjet.13605.
- [11] Angela C. F. Tam, “Interacting with ChatGPT for internal feedback and factors affecting feedback quality,” *Assessment & Evaluation in Higher Education*, 2025, doi: 10.1080/02602938.2024.2374485.
- [12] Emily Mills, Ali Mizouri, y Andrew Peach, “Prompting better feedback: A study of custom GPT for formative assessment in undergraduate physics,” *Education Sciences*, vol. 15, no. 8, 1058, 2025, doi: 10.3390/educsci15081058.
- [13] David Tensen, Peter Grainger, y Wayne Graham, “Using AI to generate formative feedback in doctoral education,” *Assessment & Evaluation in Higher Education*, 2025, doi: 10.1080/02602938.2025.2536558.
- [14] Lixiang Yan, Lele Sha, Linxuan Zhao, Yuheng Li, Roberto Martínez-Maldonado, Guanliang Chen, Xinyu Li, Yueqiao Jin, y Dragan Gašević, “Practical and ethical challenges of large language models in education: A systematic scoping review,” *British Journal of Educational Technology*, vol. 55, no. 1, pp. 90–112, 2024, doi: 10.1111/bjet.13370.
- [15] Clark A. Chinn, Robert W. Rinehart, y Luke A. Buckland, “Epistemic cognition and evaluating information: Applying the AIR model of epistemic cognition,” en *Processing inaccurate information: Theoretical and applied perspectives from cognitive science and the educational sciences*, Diane N. Rapp y Jennifer G. Braasch (Eds.), MIT Press, 2014, doi: 10.7551/mitpress/9737.003.0025.
- [16] Sharon Barzilai y Clark A. Chinn, “On the goals of epistemic education: Promoting apt epistemic performance,” *Journal of the Learning Sciences*, vol. 27, no. 3, pp. 353–389, 2018, doi: 10.1080/10508406.2017.1392968.
- [17] Sharon Barzilai y Clark A. Chinn, “The AIR and Apt-AIR frameworks of epistemic performance and growth: Reflections on educational theory development,” *Educational Psychology Review*, vol. 36, Article 91, 2024, doi: 10.1007/s10648-024-09927-5.
- [18] Deanna Kuhn y Suhyeon Park, “Epistemological understanding and the development of intellectual values,” *International Journal of Educational Research*, vol. 43, no. 3, pp. 111–124, 2005, doi: 10.1016/j.ijer.2006.05.003.
- [19] José Vicente. Álvarez-Bravo, María Antonia López-Luengo, Diego Martín de Andrés, María Victoria Vega Agapito, Francisco Hernando Gallego, y Berta San Isidro San Cristobal, “Uso de asistentes de IA en Programación Orientada a Objetos: impacto de una guía de buenas prácticas en la autopercepción y estrategias de los estudiantes,” *Actas de las JENUI*, vol. 10, pp. 361–369, 2025.

